


PODSTAWY SZTUCZNEJ INTELIGENCJI

Scenariusz 1

Maria Podkalicka, IS grupa 3

SZTUCZNY NEURON - to prosty system przetwarzający wartości sygnałów wprowadzanych na jego wejścia w pojedynczą wartość wyjściową, wysyłaną na jego jednym wyjściu (dokładny sposób funkcjonowania określony jest przez przyjęty model neuronu). Jest to podstawowy element sieci neuronowych, jego pierwowzorem był biologiczny neuron.

Budowa Neuronu Sztucznego



Neuron McCullocha-Pittsa – jeden z matematycznych modeli neuronu. Posiada wiele wejść i jedno wyjście. Każdemu z wejść przyporządkowana jest liczba rzeczywista - waga wejścia (liczba rzeczywista). Neuron ten jest podstawowym budulcem sieci neuronowej perceptron. Wartość na wyjściu neuronu obliczana jest w następujący sposób:

1. obliczana jest suma iloczynów wartości x_i podanych na wejścia i wag w_i wejść:

$$s = w_0 + \sum_{i=1}^n x_i w_i$$

2. na wyjście podawana jest wartość funkcji aktywacji $f(s)$ dla obliczonej sumy

FUNKCJA AKTYWACJI - funkcja, według której obliczana jest wartość wyjścia neuronów sieci neuronowej.

Wykorzystałam neuron **McCullocha-Pittsa** z dwoma wejściami. Jako funkcję aktywacji wykorzystałam funkcję progową unipolarną w postaci:

$$y = \begin{cases} 0 & \text{dla } s < 0 \\ 1 & \text{dla } s \geq 0 \end{cases}$$

y-wyjście neuronu

Skorzystałam z następującego algorytmu uczenia:

- Początkowe wagi zostały wylosowane z zakresu $\langle -0.5, 0.5 \rangle$
- Sprawdziłam czy na podstawie tak przygotowanych danych wejściowych otrzymam oczekiwany wynik.

Jeżeli nie uzyskałam oczekiwanego wyniku to wykonałam następujące czynności:

- Obliczyłam błąd: $e = \text{uzyskany_wynik} - \text{oczekiwany_wynik}$
- Modyfikacja wagi: $Waga = Waga + \text{współczynnik_uczenia} * e * \text{dana_wejściowa}$, oraz $b = b + \text{współczynnik_uczenia} * e$
- Procedurę powtórzyłam dla wszystkich przygotowanych zestawów danych (kolejność użycia zestawów jest losowa) a następnie sprawdziłam błąd średniokwadratowy:

$$E = \frac{1}{2} \sum_{i=1}^p (d_i - y_i)^2$$

p-liczba przykładów do nauki

d_i -oczekiwana odpowiedź perceptronu

y_i -uzyskana odpowiedź

- Jeżeli $e > 0$ to powtarzam proces uczenia

W moim programie neuron miał wykonać operację logiczną OR:


Operacja logiczna OR przyjmuje 2 parametry binarne i odpowiada wartości 0 lub 1.

Tabela przedstawia odpowiedzi funkcji XOR dla wszystkich możliwych danych wejściowych:

| a | b | x |
|---|---|---|
| 0 | 0 | 0 |
| 0 | 1 | 1 |
| 1 | 0 | 1 |
| 1 | 1 | 1 |

| | liczba cykli uczenia | | | | | | | | | |
|------|----------------------|----|----|----|----|----|----|----|----|---------|
| ni | test 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | średnia |
| 0,01 | 50 | 48 | 51 | 41 | 38 | 39 | 45 | 10 | 59 | 42,33 |
| 0,1 | 10 | 6 | 5 | 11 | 8 | 9 | 10 | 7 | 6 | 7,89 |
| 0,2 | 5 | 6 | 10 | 7 | 5 | 5 | 6 | 7 | 4 | 6,10 |
| 0,3 | 5 | 3 | 6 | 6 | 7 | 4 | 6 | 3 | 4 | 4,88 |
| 0,4 | 6 | 9 | 3 | 4 | 3 | 8 | 5 | 7 | 5 | 5,55 |
| 0,5 | 7 | 6 | 4 | 8 | 5 | 4 | 8 | 9 | 10 | 6,55 |
| 0,6 | 8 | 9 | 5 | 10 | 6 | 8 | 5 | 8 | 7 | 7,33 |

Tabela przedstawia zależność pomiędzy współczynnikiem uczenia a ilością potrzebnych cykli uczenia.



Wykres przedstawia zależność pomiędzy współczynnikiem uczenia a średnią ilością potrzebnych cykli uczenia.

Wnioski:

Dzięki wynikom zebranych w tabeli można zauważyć, że jeśli współczynnik uczenia jest większy to przy takiej samej wartości błędu jest wykonywana większa poprawka wag, więc dla małych wartości η potrzebne jest więcej iteracji. Jednak może się też zdarzyć, że poprawka wag może być za duża dla dużych wartości η i nie przybliży nas do rozwiązania. W moich testach najlepsza wartość współczynnika uczenia wyniosła 0,3.

Kod programu:

main.cpp:

```
#include <iostream>
#include <fstream>
#include "neuron.h"

using namespace std;

double funAktywacji(double x);
double* read_csv(string plik);

int main()
{
    double *wejscie1 = read_csv("../file1.csv");
    double *wejscie2 = read_csv("../file2.csv");
    neuron *neurone1 = new neuron(64);

    neurone1->setfunkcjaAktywacji(funAktywacji);

    cout << neurone1->start(wejscie2) << endl;

    neurone1->nauka(wejscie2, 0);
    cout << neurone1->start(wejscie2) << endl;
```

```

        cout << neurone1->start(wejscie1) << endl;

        neurone1->nauka(wejscie1, 1);
        cout << neurone1->start(wejscie1) << endl;
        cout << neurone1->start(wejscie2) << endl;

        system("pause");
        return 0;
}

```

```

double funAktywacji(double x)
{
    if (x > 0)
        return 1;
    else
        return 0;
}

```

```

double* read_csv(string file)
{
    ifstream is(file);

    double *in = new double[64];
    int i = 0;
    char ch;

    while (is.get(ch))
    {
        if (ch != ',' && ch != '\n')
        {
            in[i] = ch - 48;
            i++;
        }
    }
    is.close();

    return in;
}

```

```

neuron.h:
#pragma once
typedef double(*fun1)(double x);

class neuron
{
public:
    neuron();
    neuron(int n);
    neuron(int n, double *wagi);
    ~neuron();

    void set_wagi(double *m_wagi);
    double get_wagi(int i);
    void set_wagi(double x, int i);

    void set_n(int Mn);
}

```

```

int get_n() { return n; }

void setfunkcjaAktywacji(fun1 funAktywacji);
void set_pochodna(fun1 Mpochodna);

double start(double *input);
void nauka(double *input, double output);
fun1 getPochodna() { return pochodna; };

private:
    double *wagi;
    int n;
    fun1 funAktywacji;
    fun1 pochodna;

    double sum(double *m_input);
};

```

neuron.cpp:

```

#include <iostream>
#include <cstdlib>
#include <ctime>
#include "neuron.h"

double f_rand(double f_min, double f_max)
{
    double f = (double)rand() / RAND_MAX;
    return f_min + f * (f_max - f_min);
}

neuron::neuron()
{
    wagi = NULL;
    funAktywacji = NULL;
    srand(time(NULL));
}

neuron::neuron(int Mn) :
    n(Mn)
{
    funAktywacji = NULL;
    srand(time(NULL));
    wagi = new double[n];
    for (int i = 0; i < n; i++)
    {
        wagi[i] = f_rand(0, 1);
    }
}

neuron::neuron(int Mn, double *m_wagi) :
    n(Mn),
    wagi(m_wagi)
{
    funAktywacji = NULL;
    srand(time(NULL));
}

void neuron::set_wagi(double *m_wagi)
{

```

```

        wagi = m_wagi;
    }
    double neuron::get_wagi(int i)
    {
        if (wagi != NULL && i < n)
        {
            return wagi[i];
        }
        else
        {
            throw "error-getWagi";
        }
    }
}
void neuron::set_wagi(double x, int i)
{
    if (wagi != NULL && i < n)
    {
        wagi[i] = x;
    }
    else
    {
        throw "error-set_wagi";
    }
}
void neuron::set_n(int Mn)
{
    n = Mn;
}
}
void neuron::setfunkcjaAktywacji(fun1 m_funkcjaAktywujaca)
{
    funAktywacji = m_funkcjaAktywujaca;
}
void neuron::set_pochodna(fun1 Mpochodna)
{
    pochodna = Mpochodna;
}
double neuron::start(double *inputs)
{
    if (funAktywacji == 0)
        throw "ustaw funkcje aktywacji!";
    double a = sum(inputs);
    return funAktywacji(a);
}
double neuron::sum(double *m_input)
{
    double suma = 0;
    for (int i = 0; i < n; i++)
    {
        suma += wagi[i] * m_input[i];
    }

    return suma;
}
void neuron::nauka(double * input, double output)

```

```
{
    if (funAktywacji == 0)
        throw "ustaw funkcje aktywacji!";

    double ni = 0.5;
    double result = this->start(input);
    if (result != output)
    {
        for (int i = 0; i < n; i++)
        {
            wagi[i] += ni*(output - result)*input[i];
        }
    }

}

neuron::~neuron()
{
    delete wagi;
}
```